

Laboratório 1

Ciência de Dados e Big Data
Prof Adailton de Jesus Cerqueira Junior

Neste laboratório vamos gerar conhecimento a partir de dados utilizando a linguagem de programação Python e o ambiente de desenvolvimento do Google Colab.

Você é analista de uma cooperativa agrícola e recebeu dados de produção de soja por município. Ao longo deste laboratório, esses dados serão transformados, passo a passo, em conhecimento capaz de sustentar uma decisão real de negócio.

Pré-requisitos:

- Conta Google (para acesso ao Google Colab: <https://colab.research.google.com>) ou Jupyter Notebook instalado localmente.
- Bibliotecas pandas, numpy e matplotlib (já disponíveis no Colab).

Preparando o ambiente:

1 – Crie um notebook e importe as três bibliotecas que serão utilizadas no laboratório.

```
# Bibliotecas essenciais do curso
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

2 – Em projetos reais os dados vêm de sistemas, sensores ou planilhas.

Neste laboratório vamos simular um conjunto de dados de produção agrícola, para termos controle total sobre a origem dos números.

3 – Vamos iniciar o *seed* da biblioteca *random* e gerar a categoria dos municípios.

```
np.random.seed(42) # reprodutibilidade

municipios = ['Rio Verde', 'Sorriso', 'Uberlândia', 'Cascavel', 'Dourados',
              'Luís Eduardo Magalhães', 'Cristalina', 'Palmas']
```

4 – Vamos criar um DataFrame com os dados simulados do ano, da área plantada e chuva acumulada por município.

```
dados = pd.DataFrame({
    'municipio': np.random.choice(municipios, 200),
    'ano': np.random.choice([2023, 2024, 2025], 200),
    'area_ha': np.random.uniform(50, 2000, 200).round(1),
    'chuva_mm': np.random.normal(1100, 250, 200).round(0),
})
```

5 – Vamos criar a coluna, com os dados simulados, da produtividade por município.

```
# Produtividade (sacas/ha) influenciada pela chuva + ruído
dados['produtividade_sc_ha'] = (
    35 + 0.02 * (dados['chuva_mm'] - 800) + np.random.normal(0, 5, 200)
).round(1)
```

De dado para informação:

Informação é dado organizado e contextualizado.

1 – Vamos usar as funções *head*, *info* e *describe* para exibir os dados e coletar algumas informações.

2 – A função *head* exibirá os 5 primeiros registros dos dados.

```
dados.head()
```

3 – A função *info* mostrará a quantidade de linhas, as colunas, quantas nulas e os tipos de dados.

```
dados.info()
```

4 – A função *describe* mostrará um resumo estatístico.

```
dados.describe().round(1)
```

5 – Agora vamos gerar a produtividade média por município.

```
prod_municipio = (dados.groupby('municipio')['produtividade_sc_ha']
                    .mean().sort_values(ascending=False).round(1))
prod_municipio
```

De informação para conhecimento:

Conhecimento é informação interpretada, que sustenta uma decisão.

1 – Vamos verificar se a chuva explica a produtividade.

```
correlacao = dados['chuva_mm'].corr(dados['produtividade_sc_ha'])
print(f'Correlação chuva x produtividade: {correlacao:.2f}')

plt.figure(figsize=(8, 5))
plt.scatter(dados['chuva_mm'], dados['produtividade_sc_ha'], alpha=0.6)
plt.xlabel('Chuva acumulada (mm)')
plt.ylabel('Produtividade (sacas/ha)')
plt.title('Mais chuva, mais soja: relação positiva entre chuva e produtividade')
plt.show()
```

2 – Existe relação positiva entre a chuva e a produtividade?

3 – Qual seria a decisão possível?

Exercícios:

1. Calcule a **área total plantada** por município (*groupby + sum*).
2. Qual município teve a **maior produtividade média em 2025**? (dica: filtre com `dados[dados['ano'] == 2025]`).
3. Crie um gráfico de barras da produtividade média por município.